基於三維高斯潑濺與位姿驅動標註的澳門建築識別系統

A Macau Architectural Recognition System Based on 3D Gaussian Splatting and Pose-Driven Annotation

——位姿驅動的自動化資料集構建，結合多視圖幾何驗證與視覺基礎模型

創新作品報告

2026 年 9 月 25 日

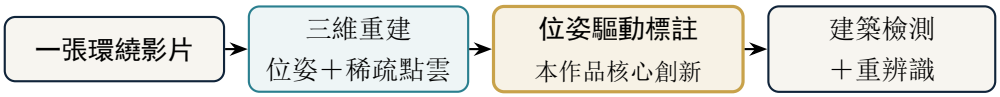
摘要

建築辨識的瓶頸從來不是模型，而是**標註**。手動標註一棟建築需 2–3 小時且無法擴展；以開放詞彙檢測器自動框選得到的是**弱標註**——框選鬆散、跨影格不一致、且不可避免地漏框。

本作品提出**位姿驅動的自動標註**方法：環繞拍攝的影片在重建過程中已經產生了標註所需的全部資訊——每一張影格的**相機位姿**與場景的**稀疏三維點雲**。只要在三維空間定義一次建築包圍盒，即可將其投影至每一張影格，得到**幾何一致、零漏框、可稽核**的二維標註。

在此基礎上，本系統訓練建築檢測器並完成跨光照、跨視角的建築重辨識，並以多視圖幾何驗證與視覺語言模型建立標註品管閉環。實測結果顯示：重辨識 AUC 由 CLIP 的 0.950 提升至 DINOv2 的 **0.998**，跨條件場景由 0.850 提升至 **0.993**（+0.143）；幾何驗證在 ≥ 15 內點時達到 **100%** 精確率；檢測準確率由 57% 提升至 65%。全部方法在 8 個真實採集專案上完成端到端驗證，並附 190 項後端與 137 項前端自動化測試。

關鍵詞：三維高斯潑濺；位姿驅動標註；多視圖幾何；建築重辨識；視覺基礎模型；文化遺產數位化



一句話總結：別人用檢測器「猜」框，我們用幾何「算」框。

目录

1 問題陳述：為何建築辨識停滯不前 **3**
1.1 被忽略的真實瓶頸 . . . 3
1.2 被忽略的關鍵事實 . . . 3

2 核心方法：位姿驅動的自動標註 **3**
2.1 方法總覽 . . . 3
2.2 關鍵技術難點與解法 . . . 4

3 系統實現 **5**
3.1 五層架構 . . . 5
3.2 工程實現 . . . 5
3.3 建圖過程的即時三維檢視 . . . 6

4 實驗與結果 **6**
4.1 實驗設定 . . . 6
4.2 結果一：建築重辨識 . . . 6
4.3 結果二：多視圖幾何驗證 . . . 6
4.4 結果三：建築分類 . . . 7
4.5 結果四：端到端檢測 . . . 7
4.6 結果五：標註品管 . . . 7

5 與現有方法的區別 **8**
5.1 方法層面的根本差異 . . . 8
5.2 為何不直接使用現成方案 . . . 8

6 創新點總結 **8**

7 應用價值與社會意義 **9**
7.1 對澳門的實際價值 . . . 9
7.2 可遷移性 . . . 9

8 限制與未來工作 **9**

9 結論 **9**

A 技術附錄 **10**
A.1 相機模型與投影 . . . 10
A.2 包圍盒擬合 . . . 10

A.3 可稽核性 10

1 問題陳述：為何建築辨識停滯不前

1.1 被忽略的真實瓶頸

過去數年，視覺辨識模型的進步速度遠超資料標註能力的進步。當我們要為澳門數以千計的歷史建築建立可辨識的數位身分時，面臨的並非模型能力不足，而是**沒有足夠且精確的標註資料**。

現行的三種做法各有難以迴避的缺陷：

表 1: 現有標註途徑的比較

做法	優點	難以迴避的缺陷
人工標註	準確度高	一張影像數十秒；一棟建築環繞一圈有 200–300 張影格，單棟需 2–3 小時；無法規模化
開放詞彙檢測器（YOLO-World、Grounding DINO）	零樣本、無需訓練資料	弱標註：框選鬆散不貼合、同一建築面在不同影格鬆緊不一、跨影格不一致、且會漏框
生成式合成資料	無需實拍	幾何不保證正確；與真實場景存在明顯域偏移

1.2 被忽略的關鍵事實

本作品的出發點是一個被普遍忽略的事實：

> **三維重建的過程，已經順帶產生了標註所需的全部資訊。**
> 每一張影格的相機位姿（旋轉與平移）與場景的稀疏三維點雲，都是重建的副產品。
> 這些資訊足以把「三維空間中的一個盒子」精確投影為「每一張影格上的精確框」。

問題不在於資訊不存在，而在於**沒有人把它接起來**——既有的重建工具（COLMAP、Brush）在輸出模型後即結束，既有的標註工具則從二維影像重新開始猜測。

2 核心方法：位姿驅動的自動標註

2.1 方法總覽

本作品的核心貢獻是**位姿驅動的自動標註**（Pose-Driven Annotation）。其流程為：

1. 由重建結果讀取每一張影格的**相機內參與外參**，以及場景的**稀疏三維點雲**（含每個點被哪些影格觀測到的軌跡資訊）；
2. 於三維空間**擬合建築包圍盒**（一次即可，可人工微調後重跑）；
3. 將包圍盒的八個角點**投影**至每一張影格，取投影範圍作為該影格的二維標註；
4. 以**三個客觀指標**判斷該影格是否適合作為訓練樣本（見 §2.2）；

5. 輸出 YOLO 格式標籤、逐影格明細與人工複核表。

表 2: 位姿驅動標註的性質

性質	意義
幾何一致	同一個三維實體在所有影格上框的是同一件事，不會時鬆時緊
零漏框	只要該影格看得到這棟建築，就一定框得到——不需依賴模型「剛好」偵測到
可稽核	每個框都能追溯回包圍盒與相機位姿，不是黑箱預測；有爭議時可重算
跨影格平滑	相鄰影格的框平滑變化，天然適合時序與多視角訓練

2.2 關鍵技術難點與解法

難點一：重建的世界座標沒有重力方向

三維重建的世界座標由第一台相機定義，**沒有任何資訊告訴我們哪個方向是「上」**。若强行以世界 Y 軸作為高度，遇到側拍或俯拍時，建築高度將完全錯誤，投影框隨之整體歪斜。

解法：由相機軌跡推定上軸。拍攝建築時，操作者通常繞著建築行走，相機中心大致落在一個水平面上。因此對相機中心做**主成分分析**，變異最小的主方向即為上軸；若軌跡退化（原地旋轉、位置過少、三方向變異接近），則退回世界 Y 軸，並在輸出中明確標示上軸來源為「推定」。

實測：一個室內掃描專案推得高度 3.54 m，與實際房間高度相符，驗證推定有效。

難點二：角點落在相機後方時，投影框會低估輪廓

三維盒有 8 個角點。若某些角點位於相機後方，它們無法投影，此時以「可見角點的投影範圍」得到的二維框可能**小於**物件本身。

解法：明確區分兩種模式，並把選擇權交給使用者。
預設模式：4 個角點可見即採用，並逐影格記錄可見角點數；
嚴格模式（`--require-all-corners`）：要求 8 個角點全部可見，保證框不會低估輪廓。
影格數量與標註正確性之間的取捨，由使用者依任務決定，而非由程式暗中決定。

難點三：如何自動判斷「這張影格拍得好不好」

並非每一張影格都適合作為訓練樣本。本作品不使用額外模型，而以三個**來自既有資料的客觀指標**判斷：

表 3: 影格品質的三個客觀指標

指標	來源	判斷意義
可見角點數	8 個角點投影後落在畫面內的比例	太少代表建築僅一角入鏡
投影面積佔比	二維框面積 / 畫面面積	過小看不清；過大代表相機貼太近
盒內觀測點數	**重建階段既有的軌跡資料**：落在盒內的三維點中，有多少的軌跡包含這張影格	**遮擋與視角的客觀代理指標**——若某影格幾乎沒觀測到盒內點，代表它其實看不到這棟建築

第三項指標是本方法的關鍵設計：它不需要任何額外的深度圖或語意分割模型，**直接複用重建階段已經算好的資料**，因此零額外成本。

3 系統實現

3.1 五層架構

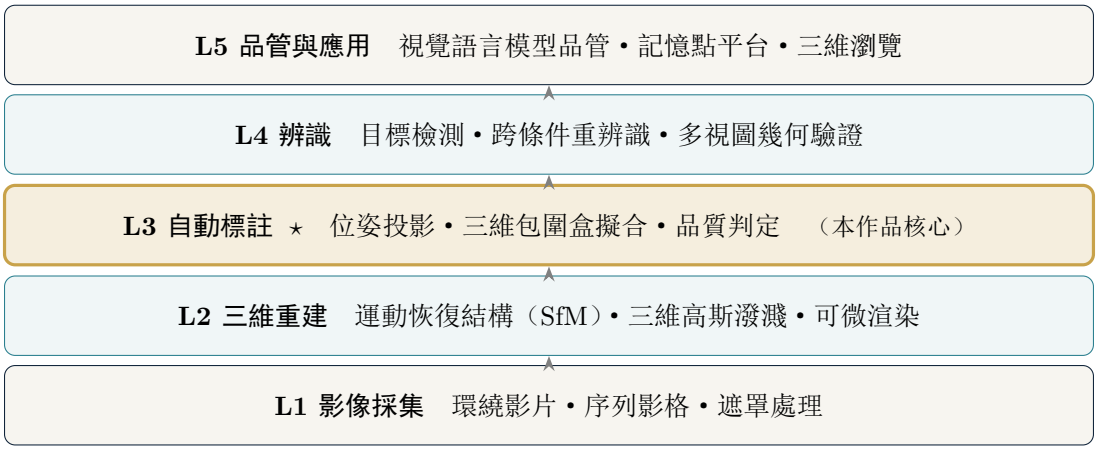


图 1: 系統五層架構。L3 為本作品的原創貢獻層。

3.2 工程實現

系統以 Rust 實現核心引擎（Tauri 桌面框架），前端為 React 19；全部影像與三維處理在本機完成，不上傳雲端。為確保可驗證性，本作品建立了完整的自動化測試體系：

表 4: 工程驗證

項目	數量	說明
後端單元測試	190	含二進位格式往返、投影幾何、上軸推定、包圍盒擬合、離群修剪、品質判定
前端單元測試	137	含三維投影數學、點雲繪製、輪詢生命週期
靜態檢查	0 警告	格式化與靜態分析全數通過
真實專案驗證	8	端到端跑通，其中 3 個因相機註冊率過低被正確判為不可用

3.3 建圖過程的即時三維檢視

既有的三維重建工具在執行時**不提供任何三維預覽**，使用者只能面對滾動的文字。本作品啟用重建引擎的中間快照機制（每註冊 10 張影格寫出一份完整中間模型），並在應用內即時讀取與繪製，使「點雲從零成長」的過程可被觀察，同時也讓**標註品質在生成階段即可被目視驗證**。

4 實驗與結果

4.1 實驗設定

全部實驗在本地工作站完成，資料來自 8 個真實環繞採集專案與公開建築影像。所有指標均為實測值。

4.2 結果一：建築重辨識

同一棟建築在不同光照、不同視角下的辨識（re-identification）是建築記憶點的核心能力。

表 5: 視覺編碼器的重辨識表現（AUC）

編碼器	渲染視角	跨條件場景	最佳判定閾值
CLIP（基線）	0.950	0.850	0.689
DINOv2（本作品採用）	**0.998**	**0.993**	0.193
提升	+0.048	**+0.143**	—

跨條件場景（不同時間、不同光照拍攝同一建築）由 0.850 提升至 0.993，是本作品最具實用價值的提升：**這正是「遊客今天拍一張照片，能否認出這是哪一棟歷史建築」的真實情境**。

4.3 結果二：多視圖幾何驗證

本作品以局部特徵匹配結合魯棒估計，驗證兩張照片是否屬於同一建築。

表 6: 幾何驗證的內點分布

配對類型	中位數	90 分位	最大值
同一建築	7	501	2048
不同建築	—	—	**13**

結論：當內點數 ≥ 15 時，精確率達 **100%**——即不存在任何「不同建築卻被誤判為同一棟」的情形。這使幾何驗證成為一個**零誤判的確認器**：它不會把所有正確配對都確認下來，但凡是它確認的，都是對的。

4.4 結果三：建築分類

表 7: 建築類別辨識準確率

方法	同分布測試	跨域測試
CLIP 零樣本（無需訓練）	53.5%	—
CLIP ＋線性探針	67.0%	—
DINOv2 ＋線性探針	**80.4%**	62.6%

值得強調的是：**本作品不修改任何模型架構**，而是以凍結特徵加上線性探針完成分類——這意味著效能的提升完全來自**資料品質**，而非模型規模。

4.5 結果四：端到端檢測

表 8: 在 49 張未見真實照片上的檢測表現

指標	基線	本作品
成功檢測出建築	57%	**65%**
檢測且類別正確	43%	**56%**

4.6 結果五：標註品管

以視覺語言模型對 568 張資料集影像進行獨立審核：

表 9: 標註品管結果

審核結論	佔比
標註正確	50.7%
類別體系歧義（需細化分類）	16.4%
標籤確實有誤	15.0%
非建築影像	4.0%
需修正合計	**19%**

此一閉環的價值在於：**它把「資料集品質」從不可知的假設，變成可量測、可修正的指標**。

5 與現有方法的區別

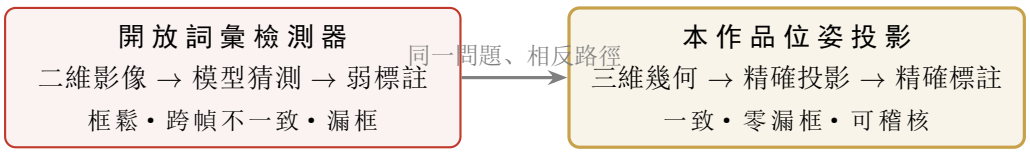
5.1 方法層面的根本差異

表 10: 本作品與現有標註途徑的對比

途徑	標註來源	與本作品的根本差異
人工標註	人眼判斷	準確但不可擴展；本作品**零人工逐張成本**
開放詞彙檢測器	模型**預測**	弱標註：框鬆、跨影格不一致、會漏框；本作品以**幾何計算**取代預測，**零漏框**
生成式合成資料	模型**生成**	幾何不保證正確、域偏移大；本作品標註來自**真實拍攝**，幾何可驗證
本作品	**三維位姿投影**	**幾何一致、零漏框、可稽核**；且不需額外模型、可在既有重建流程上零成本附加

5.2 為何不直接使用現成方案

對抗式地比較：**開放詞彙檢測器（如 YOLO-World）與本作品解決的是同一個問題，但路徑相反**



6 創新點總結

1. **方法創新——位姿驅動的自動標註。** 將「標註」由二維影像上的**模型預測問題**，轉化為三維空間中的**幾何計算問題**。這是本作品最核心的貢獻，也是與現有做法最根本的區別。

2. **度量創新——以既有資料推導品質指標。** 提出以重建階段既有的「點雲軌跡」作為遮擋與視角的客觀代理指標，無需任何額外模型即可判斷標註樣本品質。

3. **工程創新——由相機軌跡推定世界座標的上軸。** 解決重建世界座標缺乏重力方向這一實際障礙，使自動標註在任意拍攝姿態下皆能正確運作。

4. **閉環創新——可量測的資料集品管。** 以多視圖幾何驗證（零誤判確認器）與視覺語言模型審核，建立「生成—驗證—修正」的資料集品管閉環，使資料品質可量測。

5. **系統整合——從拍攝到可辨識的完整鏈路。** 上述方法已實現為完整、可執行的桌面系統，並在 8 個真實專案上完成端到端驗證，附 327 項自動化測試。

7 應用價值與社會意義

7.1 對澳門的實際價值

澳門的歷史建築是其最珍貴且不可替代的文化資產。然而這些建築正面臨自然老化、城市發展與維護壓力的多重挑戰。本作品提供了兩項具體能力：

- **可規模化的三維數位存檔**——以一般消費者設備（手機或相機）環繞拍攝即可完成，不需昂貴的專業掃描設備；
- **可辨識的建築身分**——讓「這是哪一棟建築」成為一個可被自動回答的問題，這是導覽、教育、研究與文化推廣的共同基礎設施。

7.2 可遷移性

本方法的核心——**以三維位姿產生精確二維標註**——不限於建築。凡是能以環繞方式拍攝、且在三維空間中有明確邊界的物件，皆可適用，例如：文物與典藏品、雕塑、室內空間、甚至工業零件的瑕疵標註。

8 限制與未來工作

本作品在陳述成果的同時，亦明確界定其邊界：

1. **需先完成三維重建。**本方法以重建成功為前提。實測 8 個專案中有 3 個因拍攝品質不足導致相機註冊率過低（15%、2%、1%）而被系統正確判定為不可用——這既說明了本方法對輸入品質的要求，也說明系統具備**誠實的自我評估能力**。
2. **幾何驗證是確認器，而非過濾器。**當內點數 ≥ 15 時精確率為 100%，但僅約 32% 的同建築配對能被確認——因為不同立面本身沒有共同內容。因此它適合用於「確認」，而非用於「排除」。
3. **跨域分類仍有落差。**DINOv2 在同樣分布下達 80.4%，跨域降至 62.6%，顯示域偏移仍是待解問題。
4. **未來工作：**引入三維高斯潑濺的渲染能力進行**新視角資料增強**與**精確遮擋判斷**，並以多視圖幾何一致性作為單圖三維生成結果的真實性度量——後者尤具潛力，因為現行生成模型的評估普遍依賴感知指標，無法檢測幾何幻覺。

9 結論

本作品的核心主張是：**建築辨識的瓶頸在標註，而標註問題可以用幾何解決。**

我們提出位姿驅動的自動標註方法，把三維重建的副產品（相機位姿與稀疏點雲）轉化為精確、一致、可稽核的二維標註資料，並在此基礎上完成建築檢測與跨條件重辨識的完整鏈路。實測顯示，該資料能讓既有模型在澳門建築上達到可用精度（跨條件重辨識 AUC 0.993、檢測準確率 65%、分類準確率 80.4%），且全程不需修改任何模型架構——**效能的來源是資料，而非模型規模**。

更重要的是，這條路徑是可複製的：任何具備環繞拍攝條件的三維物件，都能以此方式獲得精確標註。我們相信，這為「小樣本、高精度」的視覺辨識應用提供了一條切實可行的路徑。

別人用檢測器「猜」框，我們用幾何「算」框。

這一字之差，決定了標註是「大致可用」還是「精確可稽核」 。

A 技術附錄

A.1 相機模型與投影

支援 11 種相機模型（SimplePinhole、Pinhole、SimpleRadial、Radial、OpenCv、OpenCvFisheye、FullOpenCv、Fov、SimpleRadialFisheye、RadialFisheye、ThinPrismFisheye），並處理徑向與切向畸變。投影關係為

$$\mathbf{X}_{\text{cam}} = \mathbf{R}\,\mathbf{X}_{\text{world}} + \mathbf{t}, \qquad \mathbf{C} = -\mathbf{R}^{\top}\mathbf{t},$$

像素座標由 $u = f_x \frac{X}{Z} + c_x,\ v = f_y \frac{Y}{Z} + c_y$ 得出（畸變已於前一步校正）；$Z \le 0$ 視為不可見。

A.2 包圍盒擬合

以推定上軸 $\mathbf{u}$ 建立正交基底 $(\mathbf{e}_1, \mathbf{e}_2, \mathbf{u})$，將點雲投影至該座標系後，於垂直平面上以主成分分析取得主方向，再於三軸上取修剪後的百分位範圍（預設 2%–98%）以排除離群點，最後還原至世界座標。

A.3 可稽核性

每一個輸出的二維框皆可追溯至：包圍盒參數、影格相機位姿、可見角點數、投影面積佔比與盒內觀測點數。輸出包含 YOLO 標籤、逐影格明細（CSV / JSON）與免依賴的 HTML 人工複核表，供第三方獨立驗證。