從 CLIP 零樣本到多層驗證：

城市記憶系統的技術發展歷程

Technology Evolution of an Urban Memory System:
From Zero-Shot CLIP to a Multi-Stage Verification Pipeline

技術歷程報告

2026 年 9 月 24 日

摘要

本報告記錄「城市記憶系統」在八個階段中的技術演進：從最初的 CLIP 零樣本影像嵌入，到加入地理先驗、自訓 YOLO 建築偵測器、資料與標註的反覆清洗、視覺語言模型（VLM）介入品管、編碼器更替為 DINOv2、加入局部特徵幾何驗證，最後以 VLM 標註訓練線性探針分類器。每一階段都列出**動機、方法、量化結果、以及被推翻的假設**。核心量化結論：跨條件重辨識 AUC 由 0.850 提升至 **0.993**；真實照片的同棟 / 不同棟判別間距由 0.138 擴大到 **0.275**；幾何驗證可在「內點 $\geq$ 15」時達到 **100% 精確率**；獨立實拍分類準確率由零樣本的 53.5% 提升至 **67.0%**（訓練分布內 80.4%）。同時，本報告如實記錄了三個失敗或誤判：把分布外輸入當成方法缺陷、內部驗證集因資料洩漏而不可比、以及 DISK+LightGlue 的整合失敗。

關鍵詞：視覺場所重辨識（VPR）、CLIP、DINOv2、SALAD、幾何驗證、RANSAC、視覺語言模型、自訓練、YOLO、資料洩漏

目录

1 技術時間線總覽 **3**

2 階段 1：CLIP 零樣本重辨識 **3**

2.1 動機 . . . 3
2.2 方法 . . . 3
2.3 結果 . . . 4
2.4 暴露的三個問題 . . . 4

3 階段 2：地理先驗的引入 **4**

3.1 誤判來源分析 . . . 4
3.2 架構轉變 . . . 4

4 階段 3：為什麼要自己訓練 YOLO **5**

4.1 動機 . . . 5
4.2 如何訓練 YOLO：五步資料管線 . . . 5
4.3 第一版結果與三個教訓 . . . 5

5 階段 4：資料與標註的迭代 **6**

5.1 放寬類別關：救回被誤殺的圖 . . . 6
5.2 用已訓練模型反向清洗 . . . 6
5.3 自訓練補框 . . . 6
5.4 一個被發現的真 bug . . . 6
5.5 第二版訓練與公平對比 . . . 6

6 階段 5：視覺語言模型介入品管 **7**

6.1 動機 . . . 7
6.2 方法 . . . 7
6.3 結果（568 張） . . . 7
6.4 人工複核抽樣 . . . 7

7 階段 6：編碼器世代更替（CLIP → DINOv2） **8**

7.1 動機 . . . 8
7.2 實作要點 . . . 8
7.3 結果 . . . 8
7.4 三個關鍵發現 . . . 9

8 階段 7：幾何驗證（第二道防線） **9**

8.1 動機 . . . 9

8.2 方法 9
8.3 結果 10
8.4 定位：確認器，不是過濾器 10
8.5 誠實記錄：一次失敗的整合 10

9 階段 8：VLM 造標註 → 線性探針分類 10
9.1 動機 10
9.2 方法 10
9.3 反直覺但重要的發現 11

10 技術對照總表：什麼任務該用什麼 11

11 仍未解決的問題 12

12 下一步 12

A 完整重現指令 13

B 核心文件清單 14

1 技術時間線總覽

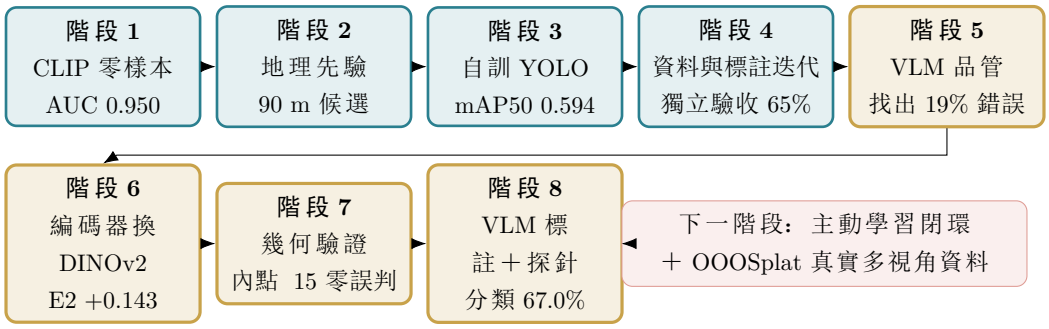


图 1: 八個技術階段。藍綠色為「建立能力」，金色為「提升精度與可信度」。

階段	做了什麼	為什麼	量化結果
1	CLIP 零樣本影像嵌入重辨識	無需標註即可判斷「是否同一棟」	受控 AUC 0.950；實拍 0.796
2	加入 90 m 地理先驗	視覺無法區分外觀相近的不同建築	路氹城誤判全部排除
3	自訓 11 類建築偵測器	COCO 80 類中沒有「建築」	mAP50 0.594（舊驗證集）
4	資料擴增與標註清洗	弱標註與樣本不足是精度瓶頸	獨立驗收偵測 57%→65%
5	DeepSeek 視覺模型品管	本地模型無法發現自己的偏誤	568 張中 19% 標註需修正
6	CLIP → DINOv2	CLIP 是圖文對比訓練，不利細粒度個體辨識	E2 0.850→0.993
7	SIFT + RANSAC 幾何驗證	為「無 GPS」情境提供第二道防線	內點 ≥15 時精確率 100%
8	VLM 標註 + 線性探針	零樣本分類只有 53.5%	獨立實拍 67.0%（+13.5 點）

表 2: 八個階段的動機與結果一覽。

2 階段 1：CLIP 零樣本重辨識

2.1 動機

一開始的目標是「判斷兩張照片是否為同一棟建築」，但沒有任何標註資料，也不可能為每棟建築收集訓練集。CLIP 的零樣本能力（以文字提示詞分類、以影像嵌入比對）看起來是最低成本的起點：512 維影像向量、餘弦相似度、無需訓練。

2.2 方法

1. 以 CLIP ViT-B/32 產生 512 維 L2 正規化影像嵌入；
2. 相似度即餘弦內積；
3. 正樣本＝同一棟建築的不同視角 / 不同拍攝者；負樣本＝不同建築；
4. 以 AUC（Mann-Whitney U 統計量）評估，並掃描閾值求 TPR/FPR。

2.3 結果

實驗	正樣本	負樣本	AUC	同棟 / 不同棟均值
E1 受控多視角渲染	330	1,440	0.950	0.901 ± 0.036 / 0.758 ± 0.073
E1b 文物	132	144	0.998	—
E1r 真實照片	205	4,845	**0.796**	0.716 ± 0.136 / 0.578 ± 0.093

表 3: CLIP 世代的基準結果。受控條件表現良好，真實照片明顯下滑。

2.4 暴露的三個問題

1. **相似建築會互相誤判：**負樣本中，澳門倫敦人與澳門銀河的平均相似度達 0.874，誤判率 72.2%。
2. **閾值不可遷移：**在渲染圖上 0.86 可認出 86.1% 的同棟，套到真實照片只剩 14.1%。
3. **分類能力被誤判：**最初以 3D 渲染圖測得「CLIP 分類只有 3.0%」，一度以為 CLIP 不能用於建築分類；補上真實照片集後發現實拍可達 53.5%——**原結論是分布外輸入造成的假象**。

3 階段 2：地理先驗的引入

3.1 誤判來源分析

把所有負樣本按建築配對拆開，逐對計算誤判率：

建築配對	平均相似度	相似度 > 0.86 的比例
澳門倫敦人 vs 澳門銀河	0.874	**72.2%**
澳門巴黎人 vs 澳門銀河	0.840	31.2%
澳門倫敦人 vs 澳門巴黎人	0.826	18.8%
其餘 7 組配對	0.70–0.75	**0.0%**

表 4: 視覺誤判 100% 集中在路氹城三棟外觀相近的度假村。

關鍵事實：這三棟建築兩兩相距**至少 296 公尺**（中位數 4,302 公尺）。以 90 公尺為半徑的地理先驗，可直接排除全部誤判候選。

3.2 架構轉變

視覺比對只負責「同一棟的不同角度」；地理先驗負責「不可能是我」。

這個分工成為後續所有設計的基礎：視覺模型不需要（也不可能）做到完美，只要在「地理上可能的候選」中做出判斷即可。

4 階段 3：為什麼要自己訓練 YOLO

4.1 動機

COCO 預訓練的 YOLO **沒有「建築」這個類別**（80 類中最接近的是「房屋」概念的缺失）。要偵測建築，必須自建資料集並微調。

4.2 如何訓練 YOLO：五步資料管線

1. **抓圖**：以 Wikimedia Commons 的**人工策展分類**（如 `Category:Churches in Macau`）為主、全文檢索為輔，並遞迴走訪子分類；以 SHA1 去重避免同一張圖重複進入資料集。
2. **CLIP 自動清洗**：三道關卡——類別關（CLIP 12 類機率）、雜物關（與「食物 / 招牌 / 人像 / 文件」等提示詞的相對相似度）、室內關（室內照對偵測器是雜訊）。清洗後保留約 44%。
3. **自動預標註**：以 YOLO-World 開放詞彙偵測「建築在哪」，**類別直接採用資料夾標籤**，因此人工只需修正框、不需重新分類。
4. **防洩漏＋分層切分**：以「檔名建築鍵＋ CLIP 相似度」雙重分組，確保同一棟建築不會同時出現在訓練與驗證集；再按類別分層，保證每個類別在驗證集都有代表。
5. **訓練**：YOLO11n、100 epochs、640 px、batch 16。

4.3 第一版結果與三個教訓

類別	訓練張數	AP50	備註
中式廟宇 temple	37	0.995	外觀獨特
葡式殖民 portuguese	32	0.845	
現代高層住宅	21	0.822	
天主教教堂 church	31	0.795	與騎樓唐樓易混
牌坊紀念物 monument	51	0.675	
工業倉庫 industrial	14	0.670	樣本過少
村落民居 village	47	0.650	
騎樓唐樓 tong_lau	21	0.404	
酒店娛樂場 casino_hotel	29	0.318	與高層住宅易混
公共建築 civic	29	0.271	
街市 market	10	0.089	樣本過少且含非建築場景
全體	**322**	**0.594**	mAP50-95 = 0.410

表 5: 第一版 YOLO11n 的驗證集結果。

1. **弱標註是最大瓶頸**：框由 YOLO-World 產生，位置正確但不夠緊，直接壓低 mAP50-95。
2. **驗證集分數會高估**：另以完全獨立的照片集驗收，發現**未見過的建築偵測率僅 37%**，與驗證集的 0.594 落差巨大。
3. **類別極度不平衡**：村落 55 張 vs 街市 10 張，AP 相差十倍以上。

5 階段 4：資料與標註的迭代

5.1 放寬類別關：救回被誤殺的圖

第一版的「類別關」用 CLIP 的 top-1 類別做硬性判斷，但 CLIP 會把大三巴牌坊判成「教堂」——這是分類體系差異，不是資料錯誤。把類別關放寬後：

類別	嚴格清洗	放寬後	變化
街市 market	47	83	+36
騎樓唐樓 tong_lau	35	78	+43
工業倉庫 industrial	30	64	+34
公共建築 civic	41	80	+39
天主教教堂 church	36	61	+25
總計	**496**	**727**	**+231**

表 6: 放寬類別關後救回 231 張，正好補上最缺乏的類別。

5.2 用已訓練模型反向清洗

抽樣目視後發現放寬的代價：`church` 資料夾裡出現現代高樓、`tong_lau` 裡出現度假村。因此以「在乾淨子集上訓練出來的模型」當裁判，把「模型強烈認為不是這個類別」（信心 ≥ 0.55）的圖移到 `images/suspect/`：

- 727 張中，模型同意 435、模型沒偵測到 200、**強烈不同意 62**（8.5%）；
- 流向合理：`tong_lau`→ 度假村 6 張、→ 高層住宅 5 張。
- 最終可用資料：**665 張**（相較第一版 496 張增加 34%）。

5.3 自訓練補框

以第一版模型掃描「YOLO-World 漏掉、尚未進入訓練集」的圖，能補上 **33 張**（信心 ≥ 0.5）。數量不多，但證明自訓練閉環可行——限制在於第一版模型本身還不夠強。

5.4 一個被發現的真 bug

三個品管腳本都用 `stem.split("_")[0]` 取類別，遇到**多字類別名**（`casino_hotel`、`tong_lau`、`residential_tower`）會切成 `casino` / `tong` / `residential`，導致 **130 張（23%）被靜默跳過**。修正為「最長前綴匹配」後，覆蓋率由 438 張回到 **568 張**。

> **教訓：**如果沒有檢查「腳本實際處理了幾張」，這個 bug 會讓所有品管結論只覆蓋 77% 的資料，而漏掉的正好是三個最需要檢查的類別。

5.5 第二版訓練與公平對比

第二版改用 **YOLO11s（943 萬參數，第一版 260 萬）**、**768 px**（第一版 640）、**451 張訓練**（第一版 322）、150 epochs + cosine LR。

評估方式	第一版 yolo11n	第二版 yolo11s	說明
內部驗證集 mAP50（117 張，兩者共同）	0.691	0.519	**不公平**：新驗證集部分來自舊訓練集
獨立照片：偵測率	57%	**65%**	兩者都沒見過
獨立照片：類別準確率	43%	**56%**	
獨立照片：訓練見過者	95% / 95%	93% / 92%	略降（不再死背）

表 7: 在同一組獨立照片上的公平對比。內部驗證集因資料洩漏而不可比。

方法論教訓：當驗證集被重新切分後，舊模型可能「訓練時見過」新驗證集的圖，分數會被灌水（本例中 `monument` 出現 0.984 vs 0.348 這種極端差距）。**唯一可靠的比較方式是完全獨立的外部資料集。**

6 階段 5：視覺語言模型介入品管

6.1 動機

本地模型（CLIP 判斷、自訓 YOLO）有兩個無法自我發現的盲點：一是 CLIP 的類別偏見（大三巴＝教堂），二是自訓模型只學過現有標註，無法察覺標註本身的錯誤。需要一個**第三方裁判**。

6.2 方法

使用 DeepSeek 視覺模型（`deepseek-flash`，官方 API 已支援圖片輸入）：

- 每次請求送 12 張圖，要求**只輸出 JSON**（類別＋信心）；
- `detail: low` 將圖片壓到 512×512，**每張圖僅約 238 tokens**；
- 結果寫入本機快取（`.cache/vlm/labels.json`），重跑不再計費；
- 加上「類別定義歧義表」：如 `monument`↔`church`（大三巴牌坊本身是教堂遺址）、`portuguese`↔`civic`，這類不一致不自動改標註。

6.3 結果（568 張）

VLM 判定	張數	占比	處理
同意（高信心）	288	50.7%	保留
類別定義歧義	93	16.4%	人工複核，不自動改
真錯誤（跨類別）	85	15.0%	修正標籤
不是建築物	23	4.0%	移出訓練集
不同意（低信心） / 同意（低信心）	65 / 37	18.0%	保留

表 8: VLM 品管結果：合計 108 張（19%）的標註需要修正。

6.4 人工複核抽樣

對 13 張「高信心反對」的圖逐張目視判斷，結論：**約 10 張 VLM 是對的**，抓到的是本地模型完全無法發現的錯誤類型——「街市」資料夾裡是市場**室內攤位**、「村落」裡是**黃色教堂**、「廟宇」裡

根本沒有建築、「工業」裡是石牆紀念物、「公共」裡有 3 張明顯是葡式殖民建築。其中 2 張是**類別定義歧義**（大三巴牌坊：VLM 說教堂、我們的體系歸為牌坊），正是需要人工而非自動處理的情況。

7 階段 6：編碼器世代更替（CLIP → DINOv2）

7.1 動機

CLIP 是「影像—文字對比」訓練出來的，特徵偏向語意類別，對「同一棟建築的不同角度」這種細粒度個體辨識天生不利。DINOv2 是純視覺自監督，特徵保留更多實例細節，是目前視覺場所重辨識（VPR）領域的主流骨幹。

7.2 實作要點

- 以 `transformers` 載入 `facebook/dinov2-base`，取 CLS token 與 patch token 的 GeM 池化（$p = 3$），並做水平翻轉平均；
- **等比縮放最短邊＋中心裁切**（保留外觀比例），而非直接壓成正方形；
- 特徵快取**依編碼器分檔**（`embeddings-<model>.npz`），避免換模型時誤用舊特徵。

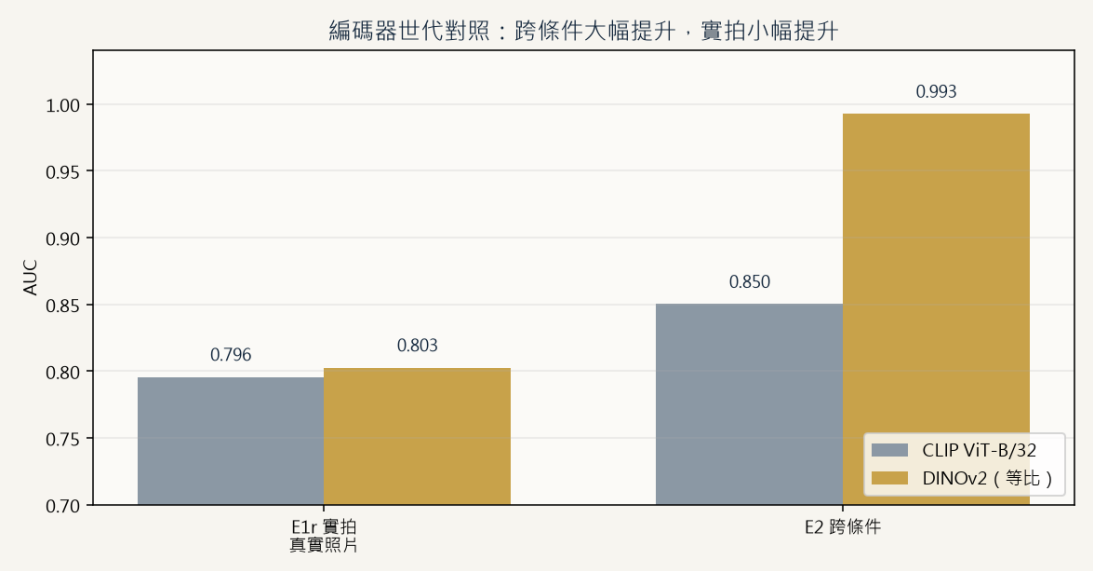


图 2: 編碼器世代對照。跨條件（E2）提升最顯著，實拍（E1r）小幅提升。

7.3 結果

設定	E1	E1b	E1r	E2	實拍最佳閾值
CLIP ViT-B/32（原基準）	0.950	0.998	0.796	0.850	0.689
DINOv2（壓成正方形）	0.998	1.000	0.789	0.993	0.534
DINOv2（等比＋裁切）	**0.998**	1.000	**0.803**	**0.993**	**0.193**

表 9: 編碼器對照。DINOv2 在受控與跨條件上大幅領先。

7.4 三個關鍵發現

1. **判別間距翻倍**：實拍的同棟 / 不同棟相似度差距由 0.138 擴大到 **0.275**。間距比 AUC 更能反映「閾值穩不穩、能不能泛化到新資料」。
2. **預處理比換模型更重要**：壓成正方形 0.789、等比縮放＋中心裁切 0.803。這個 0.014 的差距**比 CLIP 與 DINOv2 之間的差距還大**。
3. **產品閾值必須重新校準**：CLIP 最佳閾值 0.689，DINOv2 是 **0.193**（DINOv2 餘弦值整體偏低）。原先產品使用的 0.86 對兩者都不適用。

附帶發現：輸入邊長 336 px 與 518 px 的結果**完全相同**，池化方式（CLS 或 CLS+GeM）與翻轉增強影響也都在 0.002 以內——因此採用 336 px 以節省算力。

8 階段 7：幾何驗證（第二道防線）

8.1 動機

地理先驗能排除「外觀相近但距離很遠」的誤判，但**沒有 GPS 時就失效**（室內、地下、GPS 漂移）。幾何驗證提供不依賴位置的第二道防線：同棟不同角度會有大量**幾何一致**的特徵對應；不同棟即使整體相似，也難以找到一致的內點。

8.2 方法

1. 全局檢索：DINOv2 餘弦相似度取 top-1 候選（門檻 0.15）；
2. 局部特徵：OpenCV SIFT（最多 2048 關鍵點）＋ Lowe 比率檢驗（0.75）；
3. 幾何一致性：`cv2.findHomography` 搭配 **USAC_MAGSAC** 穩健估計，統計內點數。

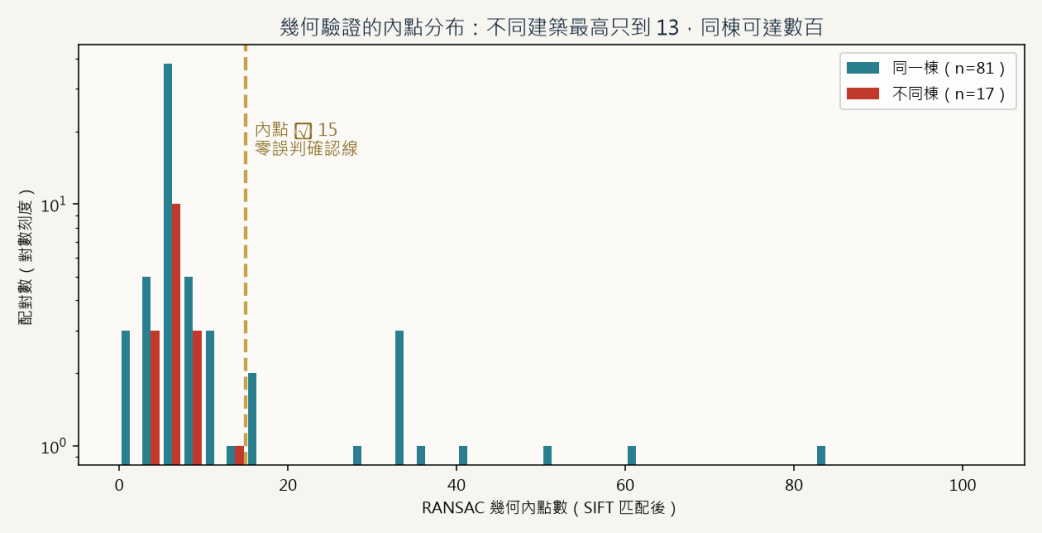


图 3: 內點分布完全分離：不同建築最高只到 13 個內點，同棟可達數百。

8.3 結果

組別	中位內點	p90	最大	內點為 0 的比例
同一棟建築	7	**501**	2048	4%
不同建築	6	8	**13**	0%

表 10: 內點分布：不同建築的上限只有 13，形成天然的安全邊界。

內點門檻	接受同棟	接受不同棟	精確率	召回
5	73	14	83.9%	90.1%
10	30	1	96.8%	37.0%
15	26	**0**	**100%**	32.1%
20	24	0	100%	29.6%

表 11: 內點門檻掃描。≥ 15 時誤判為零。

8.4 定位：確認器，不是過濾器

幾何驗證只能確認 **32%** 的同棟配對。原因是原理性的：**若兩張照片拍的是同一棟建築的不同立面，它們之間沒有共同的視覺內容，任何幾何方法都無法確認**。因此正確的用法是：

內點 $\geq$ 15 $\Rightarrow$ 確定同一棟（100% 精確），可直接歸戶、不需 GPS；
內點 $<$ 15 $\Rightarrow$ 退回全局相似度＋地理先驗。

8.5 誠實記錄：一次失敗的整合

同時嘗試了學習式特徵與匹配器（kornia 的 DISK + LightGlue，理論上比 SIFT 更耐大視角變化），但在 kornia 0.8.3 上**整合失敗**：無論是否對關鍵點座標做正規化，LightGlue 都回傳 0 個匹配（同一對圖 SIFT 可得 29 個匹配、7 個內點）。程式碼保留但預設使用 SIFT+RANSAC。**本階段的結論不依賴 LightGlue**。

9 階段 8：VLM 造標註 $\rightarrow$ 線性探針分類

9.1 動機

CLIP 零樣本分類在真實照片上只有 53.5%。文獻（OpenFACADES, ISPRS 2025）指出：**微調過的視覺語言模型勝過零樣本與單屬性模型**。在資料量只有數百張的限制下，「凍結特徵＋線性探針」是標準且不易過擬合的做法。

9.2 方法

1. 用階段 5 的 VLM 標註作為監督訊號（485 張，信心 ≥ 0.5，11 類）；
2. 以 DINOv2 或 CLIP 的凍結特徵訓練邏輯迴歸（`class_weight="balanced"`）；

3. 在**完全獨立的 91 張實拍 CC 照片**（人工策展標籤）上評估 top-1 準確率；

4. 以 5 折交叉驗證觀察訓練分布內的表現。

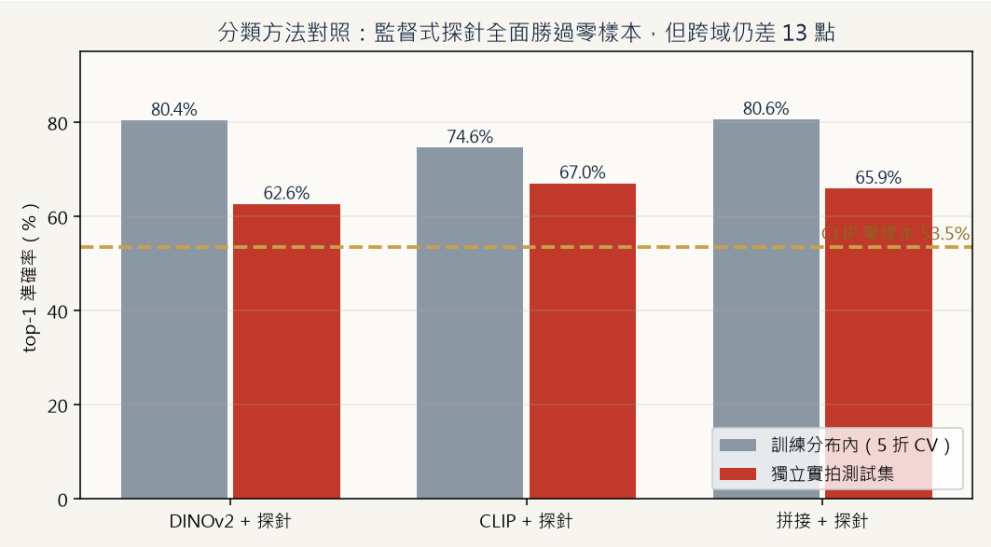


图 4: 分類方法對照：監督式探針全面勝過零樣本，但跨域仍有明顯落差。

方法	訓練分布內（5 折 CV）	獨立實拍測試集
CLIP 零樣本	—	53.5%
CLIP 特徵＋探針	74.6%	**67.0%**（+13.5 點）
DINOv2 特徵＋探針	**80.4%**	62.6%
拼接（CLIP ＋ DINOv2）	80.6%	65.9%

表 12: 分類方法對照。

9.3 反直覺但重要的發現

DINOv2 在訓練分布內更強（80.4% vs 74.6%），但 CLIP 特徵跨域泛化更好（67.0% vs 62.6%）——這是典型的小樣本域偏移現象：DINOv2 的細節特徵更容易過擬合訓練域。

> **實務結論：任務不同就該用不同編碼器。**
> 重辨識（同一棟不同角度）⇒ **DINOv2**（E2 +0.143，決定性優勢）。
> 分類（小樣本、跨域）⇒ **CLIP 特徵＋線性探針**（67.0%）。

主要混淆仍來自類別定義邊界：`church`→`monument`（大三巴）、`civic`→`casino_hotel`。獨立實拍 67.0% 與訓練分布內 80.4% 之間的 13.4 點落差，**本質是資料問題（真實照片不足），不是方法問題**。

10 技術對照總表：什麼任務該用什麼

任務	曾用技術	目前採用	依據
判斷是否同一棟（有 GPS）	CLIP 零樣本	地理先驗＋ DINOv2	90 m 先驗排除全部相似建築誤判
判斷是否同一棟（無 GPS）	CLIP 零樣本	DINOv2 ＋ SIFT/RANSAC 幾何驗證	內點 ≥15 時精確率 100%
建築類型分類	CLIP 零樣本（53.5%）	CLIP 特徵＋線性探針（67.0%）	監督式探針 +13.5 點
建築偵測（框）	COCO YOLO（無建築類）	自訓 YOLO11s（11 類）	獨立驗收偵測率 65%
標註產生	YOLO-World 自動框	＋ VLM 品管＋人工複核	找出 19% 標註錯誤
隱私處理	OpenCV 串聯分類器（失效）	YOLO11n-face ＋ person 兩級模糊	實測模糊人臉 28、人物 205
3D 場景重建	無	（規劃中）OOOSplat 3DGS	已能產出 `final.ply`

11 仍未解決的問題

1. **真實照片不足：**獨立實拍集只有 101 張、20 棟建築。分類跨域落差 13.4 點、偵測未見過建築只有 65%，根因都是資料量。這是目前最大的瓶頸。
2. **類別定義邊界：**大三巴牌坊（教堂遺址 vs 牌坊）、殖民地官邸（葡式 vs 公共建築）等 16.4% 的配對屬於體系歧義，需要明確定義或合併類別。
3. **標註仍是弱標註：**379 張的框由 YOLO-World 產生，人工尚未逐張修正。
4. **地理先驗依賴 GPS：**室內、地下、GPS 漂移時會失準，目前只能退回純視覺並標記待複核。
5. **DISK+LightGlue 整合失敗：**待排查 kornia 版本的 API 差異。
6. **隱私處理未經正式評估：**只量測了模糊數量，未量測漏接率與誤模糊率。
7. **驗證集不可比：**兩代 YOLO 的內部驗證集因重新切分而失去可比性，未來需凍結固定的外部測試集。

12 下一步

1. **主動學習閉環：**以現有分類器的預測機率與幾何內點數篩選「最不確定」的樣本（機率接近均勻、內點介於 5–15 的模糊帶），優先送 VLM / 人工標註後重訓。預期再提升 5–10 點。
2. **真實多視角資料（OOOSplat）：**以 3D 高斯潑濺工具環繞拍攝澳門建築，其 `work/frames/` 提供數十張**真實多視角照片**、`work/colmap/` 提供**精確相機位姿**。這同時解決三件事：補足真實照片不足、把重辨識評測從「GLB 渲染圖」升級為真實多視角、並可用位姿投影產生**幾何一致的精確標註**。

3. **產品閾值重新校準**：依實測把併入閾值改為 DINOv2 的 0.193（幾何驗證通過時可再放寬），並加入人工複核佇列介面。
4. **類別體系整理**：合併或明確定義 16.4% 的歧義配對，並補抓街市、工業等少樣本類別。

A 完整重現指令

```
# 階段 1-2: CLIP 基準 + 地理先驗分析
python tools/eval/render_views.py            # 7 模型 × 20 視角受控渲染（VTK 離屏）
python tools/eval/build_dataset.py           # 彙整資料集清單
python tools/eval/evaluate.py                # CLIP: AUC/ROC/閾值 + 圖表 + 報告
python tools/eval/analyze_errors.py          # 誤判來源逐對分析（路氹城案例）

# 階段 3-4: YOLO 資料管線與訓練
python tools/yolo-dataset/fetch_dataset.py --per-class 600 --subcats 2   # 抓圖（子分類遞迴 +
python tools/yolo-dataset/filter_dataset.py --restore && \
python tools/yolo-dataset/filter_dataset.py --apply --gate-exempt all   # 放寬類別關
python tools/yolo-dataset/verify_recovered.py --apply                    # 模型反向清洗
python tools/yolo-dataset/prelabel.py                                    # YOLO-World 預標註 +
python tools/yolo-dataset/refine_labels.py --scan-raw --apply            # 自訓練補框
python tools/yolo-dataset/train.py --model yolo11s.pt --imgsz 768 --epochs 150 --batch 12
python tools/yolo-dataset/eval_on_cc.py                                  # 獨立照片驗收（見過/
python tools/yolo-dataset/compare_models.py                              # 同驗證集對照新舊模

# 階段 5: VLM 品管
python tools/yolo-dataset/vlm_label.py --verify --batch 12               # DeepSeek 視覺複核
python tools/yolo-dataset/vlm_disputes.py                                # 爭議圖聯絡表（人工

# 階段 6: 編碼器對照
python tools/eval/evaluate.py --encoder dino --experiments e1,e1b,e1r,e2,e4 \
       --dino-size 336 --dino-pool cls --dino-resize shortest --out-suffix=-dino-336cls
python tools/eval/compare_encoders2.py                                   # 世代對照表

# 階段 7: 幾何驗證
python tools/eval/geo_verify.py --method sift                            # 檢索 + SIFT/RANSAC
python tools/eval/geo_sweep.py --method sift                             # 內點門檻掃描

# 階段 8: VLM 標註 + 線性探針
python tools/eval/probe_classifier.py --encoder clip                     # 67.0%
python tools/eval/probe_classifier.py --encoder dino --dino-size 336     # 62.6%
python tools/eval/make_history_figs.py                                   # 本報告所有圖表
```

B 核心文件清單

檔案	用途
`tools/eval/evaluate.py`	重辨識評測主程式（可切換編碼器、輸出完整報告與圖表）
`tools/eval/clip_embed.py`	CLIP 編碼器封裝（含正確的類別聚合順序）
`tools/eval/dino_embed.py`	DINOv2 編碼器封裝（多尺度、翻轉增強、兩種預處理）
`tools/eval/geo_verify.py`	幾何驗證（SIFT+RANSAC 與 DISK+LightGlue 兩條路）
`tools/eval/probe_classifier.py`	VLM 標註 + 線性探針分類器
`tools/eval/compare_encoders2.py`	編碼器世代對照表
`tools/yolo-dataset/fetch_dataset.py`	Commons 抓圖（子分類遞迴、SHA1 去重、授權紀錄）
`tools/yolo-dataset/filter_dataset.py`	CLIP 三道清洗關卡（類別 / 雜物 / 室內）
`tools/yolo-dataset/prelabel.py`	YOLO-World 自動框 + 防洩漏分層分組切分
`tools/yolo-dataset/refine_labels.py`	自訓練標註精煉（含 raw 補框）
`tools/yolo-dataset/verify_recovered.py`	以模型當裁判反向清洗
`tools/yolo-dataset/vlm_label.py`	DeepSeek 視覺品管（含類別歧義表）
`tools/yolo-dataset/train.py`	YOLO 訓練（暖啟動、cosine LR、增強參數）